Red and Black 170303 : id Masked

MYUNG BIN KWAK

2020-04-04

Data

```
class_roll <- read.table("../data/class_roll_masked.txt",
                         header = TRUE,
                         stringsAsFactors = FALSE,
                         encoding = "CP949")
str(class_roll)
```

```
## 'data.frame':    160 obs. of  6 variables:
##  $ dept   : chr  "ㅇㅇ학과" "ㅇㅇ학과" "ㅇㅇ학과" "ㅇㅇ학과" ...
##  $ id     : int  20119999 20119999 20179999 20149999 20169999 20129999 20149999 20169999 20179999 20129999 ...
##  $ name   : chr  "강ㅇㅇ" "강ㅇㅇ" "강ㅇㅇ" "강ㅇㅇ" ...
##  $ year   : int  4 4 1 4 2 3 4 2 1 3 ...
##  $ email  : chr  "user_name@naver.com" "user_name@hanmail.net" "user_name@naver.com" "user_name@hanmail.net" ...
##  $ cell_no: chr  "010-1164-xxxx" "010-1174-xxxx" "010-1135-xxxx" "010-1166-xxxx" ...
```

Randomization

```
set.seed(1)
N <- nrow(class_roll)
class_roll$group <- sample(1:N) %% 2
class_roll$group <- factor(class_roll$group,
                           labels = c("Red", "Black"))
red_id <- which(class_roll$group == "Red")
black_id <- which(class_roll$group == "Black")
```

학번

```
ID_16 <- factor(ifelse(substr(class_roll$id, 1, 4) >= 2016,
                       "younger_16", "older_16"),
                levels = c("younger_16", "older_16"))
kable(table("그룹" = class_roll$group,
            "16학번 기준" = ID_16))
```

	younger_16	older_16
Red	46	34
Black	41	39

```
ID_15 <- factor(ifelse(substr(class_roll$id, 1, 4) >= 2015,
                       "younger_15", "older_15"),
                levels = c("younger_15", "older_15"))
kable(table("그룹" = class_roll$group,
            "15학번 기준" = ID_15))
```

	younger_15	older_15
Red	54	26
Black	46	34

```
ID_14 <- factor(ifelse(substr(class_roll$id, 1, 4) >= 2014,
                       "younger_14", "older_14"),
                levels = c("younger_14", "older_14"))
kable(table("그룹" = class_roll$group,
            "14학번 기준" = ID_14))
```

	younger_14	older_14
Red	63	17
Black	57	23

```
ID_13 <- factor(ifelse(substr(class_roll$id, 1, 4) >= 2013,
                       "younger_13", "older_13"),
                levels = c("younger_13", "older_13"))
kable(table("그룹" = class_roll$group,
            "13학번 기준" = ID_13))
```

	younger_13	older_13
Red	75	5
Black	71	9

email 서비스업체

```
email_list <- strsplit(class_roll$email, "@", fixed = TRUE)
mail_com <- sapply(email_list, `[`, 2)
kable(table("그룹" = class_roll$group,
            "e-mail" = mail_com))
```

	daum.net	gmail.com	hanmail.net	nate.com	naver.com
Red	1	3	3	4	69
Black	1	3	6	3	66

성씨 분포

```
f_name <- substring(class_roll$name,
                    first = 1, last = 1)
kable(table("Group" = class_roll$group,
            "Family Name" = f_name))
```

	강	고	구	권	김	나	명	문	박	반	방	배	서	성	손	송	신	심	안	양	우	유	윤	이	임	장	전	정	조	차	최	하	한	황
Red	2	0	1	1	19	1	1	1	6	1	0	1	2	1	1	1	3	1	3	0	1	3	1	12	0	2	1	1	3	1	5	1	1	2
Black	4	1	0	3	17	0	0	0	7	0	1	1	2	0	1	2	0	0	2	1	0	2	4	10	2	1	1	7	4	1	4	0	1	1

많이 나오는 성씨

```
f_name_f <- factor(ifelse(f_name %in% c("김", "이", "박"),
                          f_name, "기타"),
                   levels = c("김", "이", "박", "기타"))
kable(table("Group" = class_roll$group,
            "Family Name" = f_name_f))
```

	김	이	박	기타
Red	19	12	6	43
Black	17	10	7	46

전화번호의 분포

```
cell_numbers <- sapply(substr(class_roll$cell_no, 5, 8),
                       as.numeric)
# cut_label <- c("1100~1109", "1110~1119", "1120~1129", "1130~1139", "1140~1149", "1150~1159",
#                "1160~1169", "1170~1179", "1180~1189", "1190~1199")
cut_label <- paste(paste0(seq(1100, 1190, by =10)), paste0(seq(1109, 1199, by = 10)), sep = "~")
kable(t(table(cut(cell_numbers,
                  labels = cut_label,
                  breaks = seq(1100, 1200, by = 10)))))
```

1100~1109	1110~1119	1120~1129	1130~1139	1140~1149	1150~1159	1160~1169	1170~1179	1180~1189	1190~1199
14	20	22	14	13	15	13	22	12	14

```
hist(cell_numbers)
```

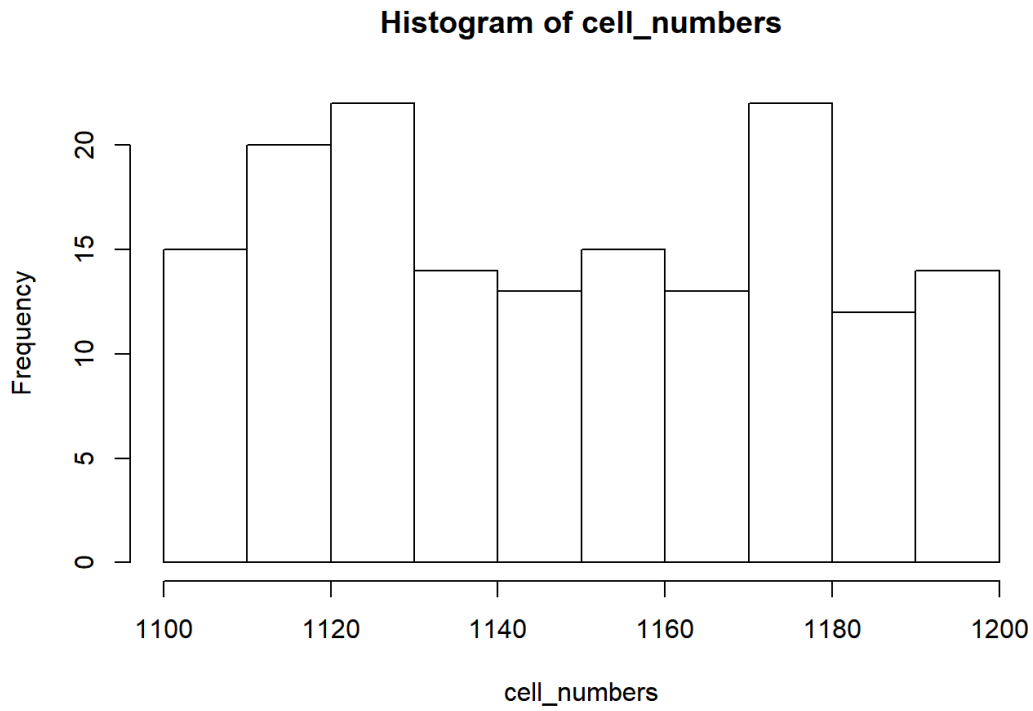

출석부에서 8명 비복원 랜덤 표집

```
# set.seed(1)
kable(class_roll[sample(1:nrow(class_roll), size = 8), ])
```

	dept	id	name	year	email	cell_no	group
140	ㅇㅇ학과	20169999	조ㅇㅇ	2	user_name@naver.com (mailto:user_name@naver.com)	010-1125-xxxx	Black
126	ㅇㅇ학과	20139999	장ㅇㅇ	3	user_name@naver.com (mailto:user_name@naver.com)	010-1173-xxxx	Black
14	ㅇㅇ학과	20119999	김ㅇㅇ	3	user_name@naver.com (mailto:user_name@naver.com)	010-1109-xxxx	Black
116	ㅇㅇ학과	20119999	이ㅇㅇ	4	user_name@naver.com (mailto:user_name@naver.com)	010-1152-xxxx	Black
16	ㅇㅇ학과	20139999	김ㅇㅇ	2	user_name@naver.com (mailto:user_name@naver.com)	010-1195-xxxx	Red
15	ㅇㅇ학과	20169999	김ㅇㅇ	2	user_name@naver.com (mailto:user_name@naver.com)	010-1164-xxxx	Red
130	ㅇㅇ학과	20129999	정ㅇㅇ	4	user_name@naver.com (mailto:user_name@naver.com)	010-1111-xxxx	Black
65	ㅇㅇ학과	20179999	반ㅇㅇ	1	user_name@naver.com (mailto:user_name@naver.com)	010-1190-xxxx	Red

set.seed() 의 용법

`set.seed()` 를 이용하면 랜덤넘버에 의존하는 실험을 재현할 수 있다. 다음 코드를 반복 수행하거나 다른 사람들의 수행결과와 비교해 보라.

세 결과가 모두 다른 경우

```
sample(1:6, size = 2)
```

```
## [1] 3 1
```

```
sample(1:6, size = 2)
```

```
## [1] 6 1
```

```
sample(1:6, size = 2)
```

```
## [1] 4 5
```

세 번의 수행 결과가 똑같이 반복되는 경우

```
set.seed(1)
sample(1:6, size = 2)
```

```
## [1] 1 4
```

```
sample(1:6, size = 2)
```

```
## [1] 1 2
```

```
sample(1:6, size = 2)
```

```
## [1] 5 3
```

동일한 결과를 반복적으로 얻는 경우

```
set.seed(1)
sample(1:6, size = 2)
```

```
## [1] 1 4
```

```
set.seed(1)
sample(1:6, size = 2)
```

```
## [1] 1 4
```

```
set.seed(1)
sample(1:6, size = 2)
```

```
## [1] 1 4
```